Detekcia podvodných transakcií

Od analýzy transakcií k detekcii podvodov

(Case study: Prevencia fraudov)

Miroslava Mäsiariková

Metodológia

- **Problém:**
  - Identifikácia podvodných transakcií v dátach s výraznou nerovnováhou tried
  - Minimalizácia počtu nezachytených podvodov pri zachovaní zvládnuteľného množstva alertov

- **Použitý prístup:**
  - Exploratory data analysis (EDA)
  - Feature engineering
  - Strojové učenie
  - Optimalizácia hyperparametrov
  - Optimalizácia rozhodovacieho prahu
  - Interpretovateľnosť pomocou SHAP

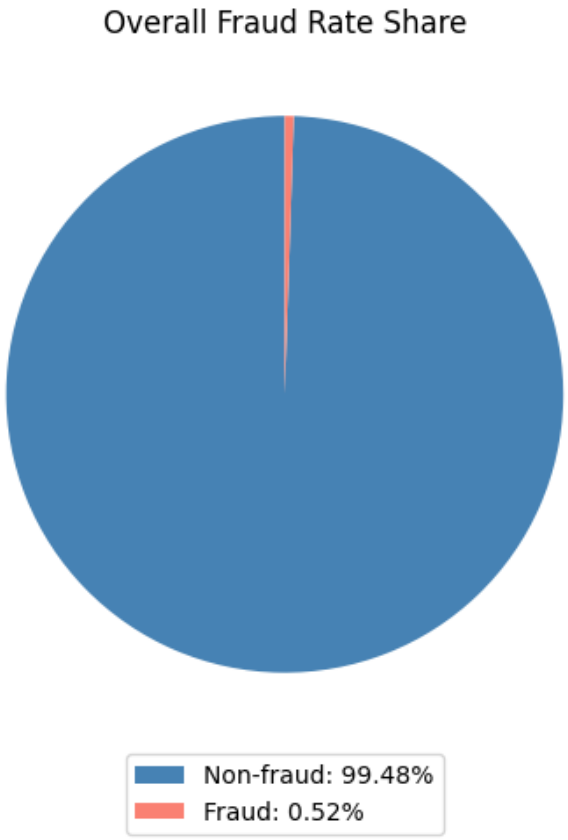
Definícia problému

- Podvodné transakcie tvoria len malú časť celkového objemu transakcií
- Nezachytené podvody môžu viesť k finančným stratám a nespokojnosti klientov
- Vysoký počet False Positives zvyšuje pracovnú záťaž vyšetrovateľov
- Správanie podvodníkov sa postupne mení a prispôsobuje existujúcim pravidlám

- **Cieľ**:
  - Navrhnúť model, ktorý dokáže identifikovať rizikové transakcie a zároveň rešpektuje prevádzkové obmedzenia fraud prevention tímu

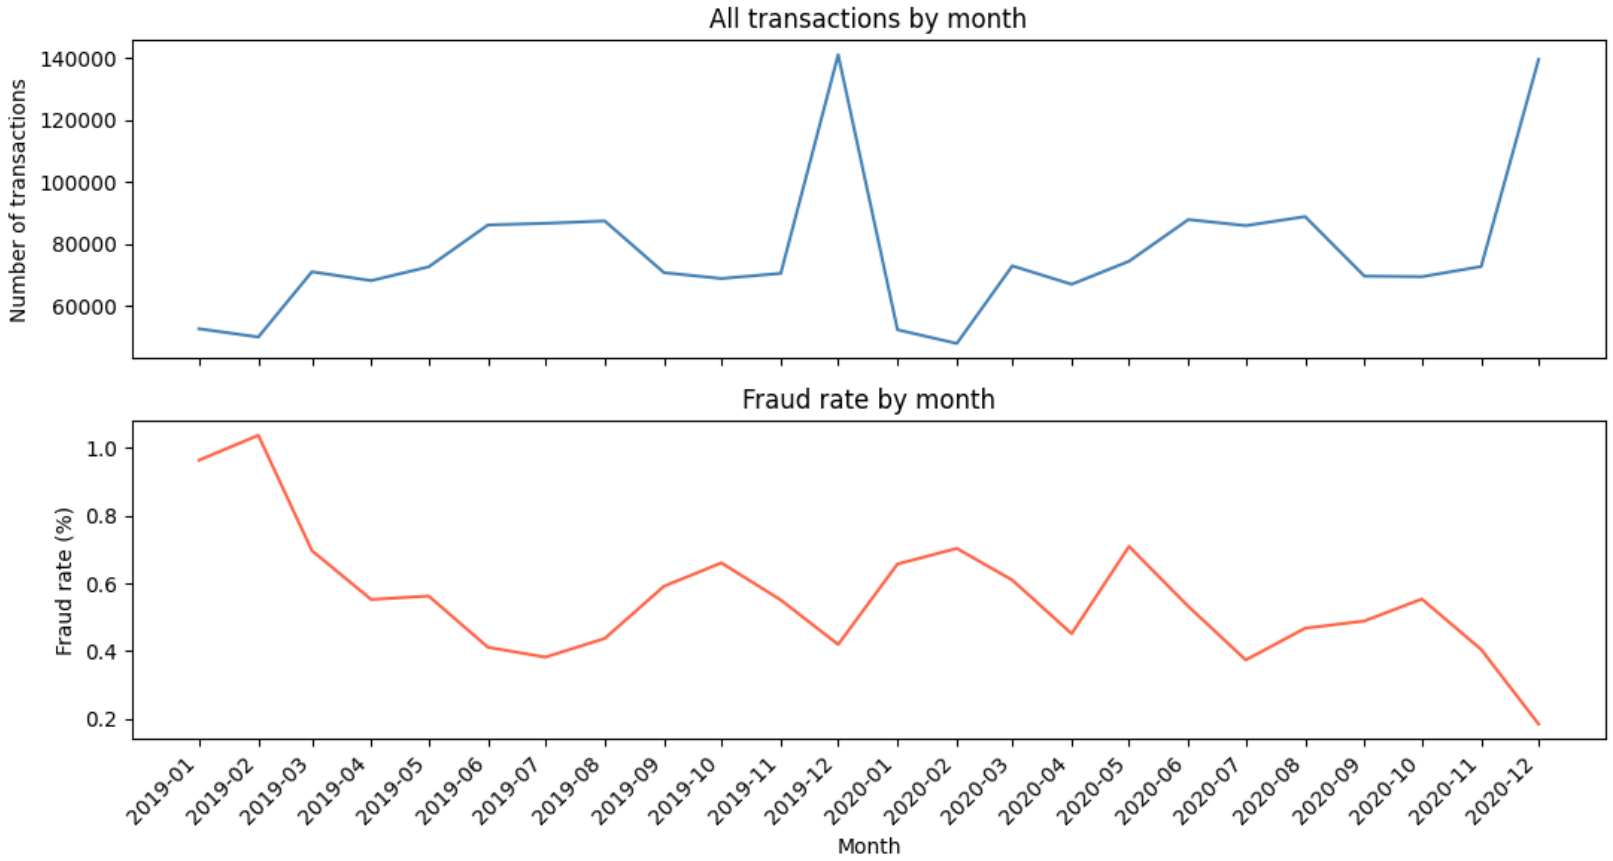
Charakteristika dát

- **Počet transakcií:** 1 852 394
- **Počet fraud transakcií:** 9 651
- **Miera podvodov (Fraud rate):** 0.52%
- **Počet atribútov:** 22
- **Časové obdobie:** 1.1.2019 – 31.12.2020
- **Počet unikátnych klientov:** 999
- **Počet klientov bez podvodu:** 23
- **Počet obchodníkov:** 693

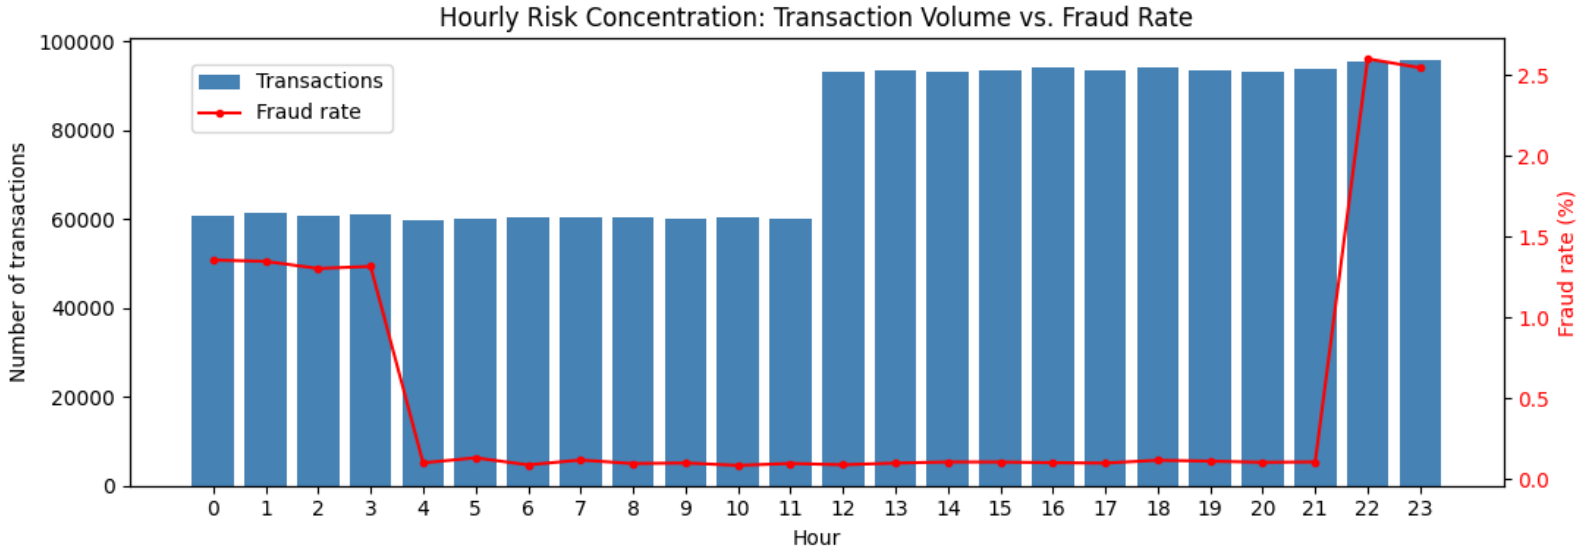


EDA

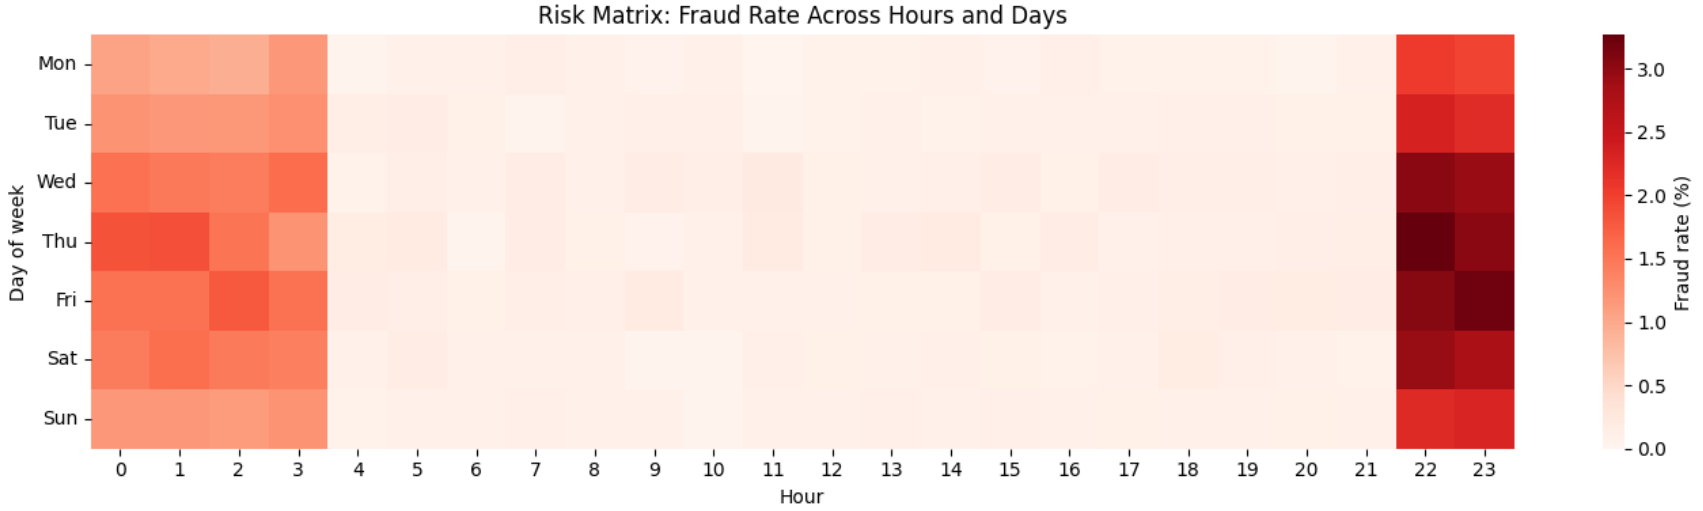
- V dátach existujú výrazné sezónne výkyvy
- Nárast počtu transakcií neznamená priamy nárast fraudov



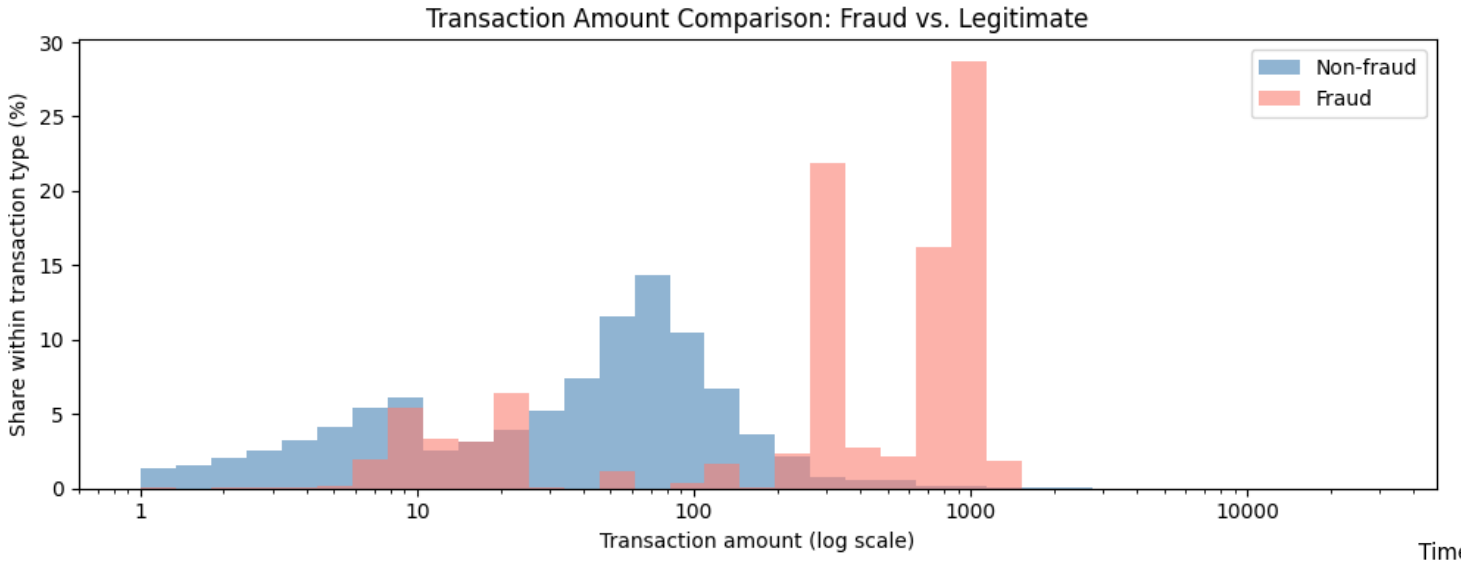
EDA



- Kritická koncentrácia podvodov v nočných hodinách (22:00 – 03:00)

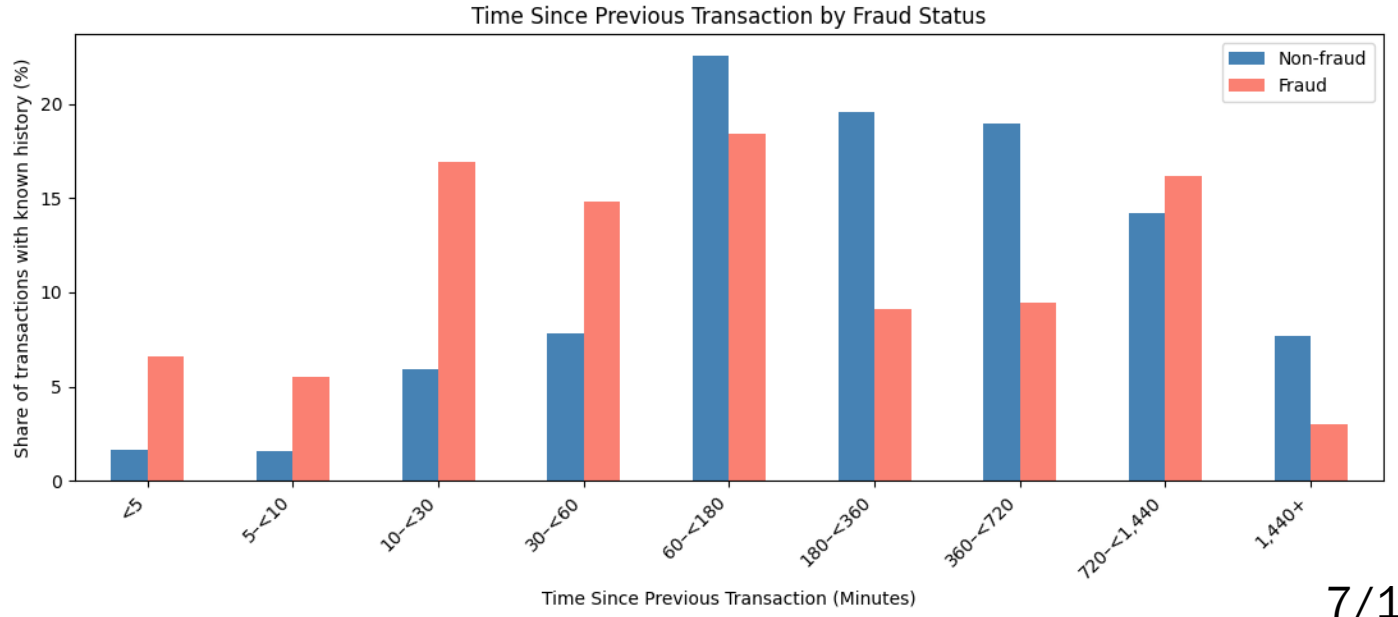


EDA

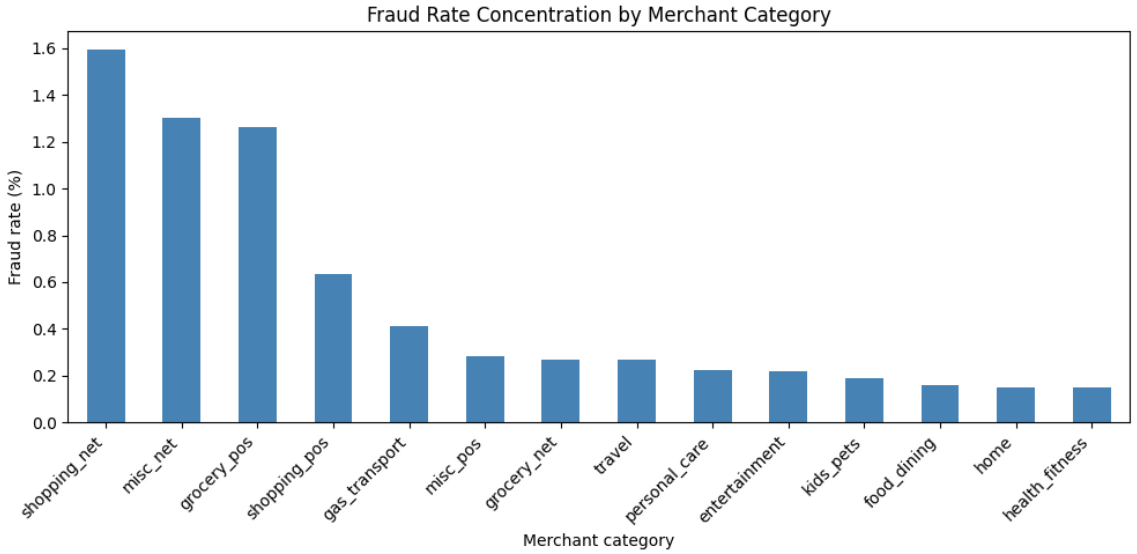


- Kým bežné platby prevažujú v nižších sumách, podvody sa výrazne koncentrujú vo vyšších čiastkach

- Podvody sú častejšie v tesnej nadväznosti na predchádzajúcu aktivitu, čo signalizuje rýchle preposielanie peňazí

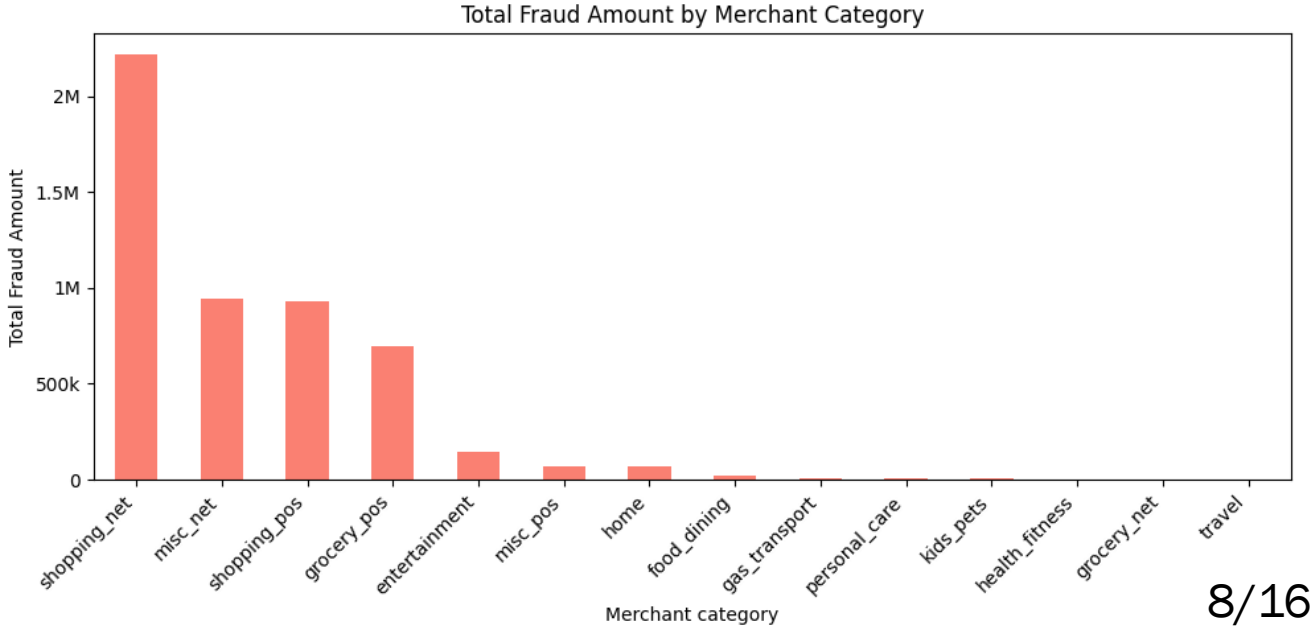


EDA



- Najvyššiu mieru podvodov vykazujú online kategórie

- Z pohľadu celkovej finančnej straty jednoznačne dominujú online nákupy s vyše 2 miliónmi, čím sú najrizikovejšou oblasťou



Feature engineering

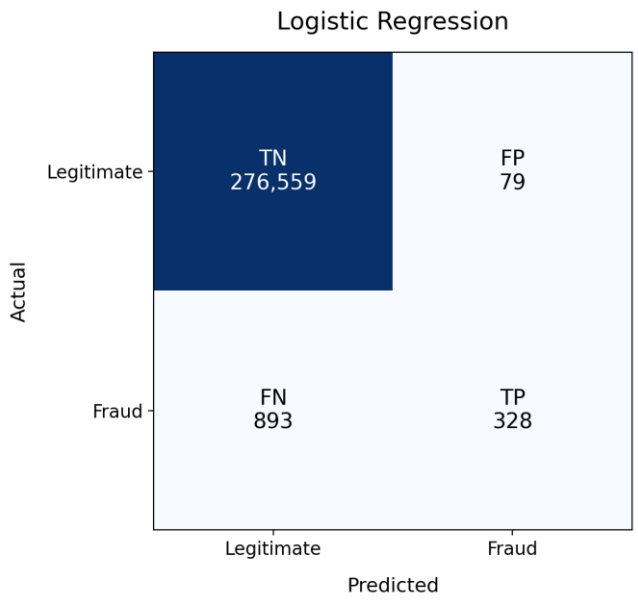
- **Časové charakteristiky:**
  - *hour, day_of_week, is_weekend, is_night, is_evening, hour_sin/cos*
  - Identifikácia časových vzorcov a transakcií realizovaných v neobvyklých hodinách
- **Charakteristiky výdavkov klienta:**
  - *customer_avg_amt, customer_median_amt, amount_vs_avg, amount_zscore*
  - P*orovnanie aktuálnej sumy transakcie s historickými výdavkami klienta*
- **Transakčné správanie klienta:**
  - *tx_count_1h/24h/7d, tx_amount_sum_24h/7d, time_since_last_tx, unique_merchants_7d*
  - Sledovanie frekvencie, objemu a intenzity transakcií v rôznych časových intervaloch
- **Geografické charakteristiky:**
  - *customer_merchant_distance_km, avg_customer_distance, distance_vs_avg*
  - Vyhodnotenie vzdialenosti medzi klientom a obchodníkom v porovnaní s obvyklým správaním klienta
- **Charakteristiky obchodníkov a kategórií:**
  - *merchant_tx_count_history, unique_merchants_7d, unique_categories_7d/30d*
  - Zachytenie nových obchodníkov a kategórií vzhľadom na predchádzajúcu aktivitu klienta

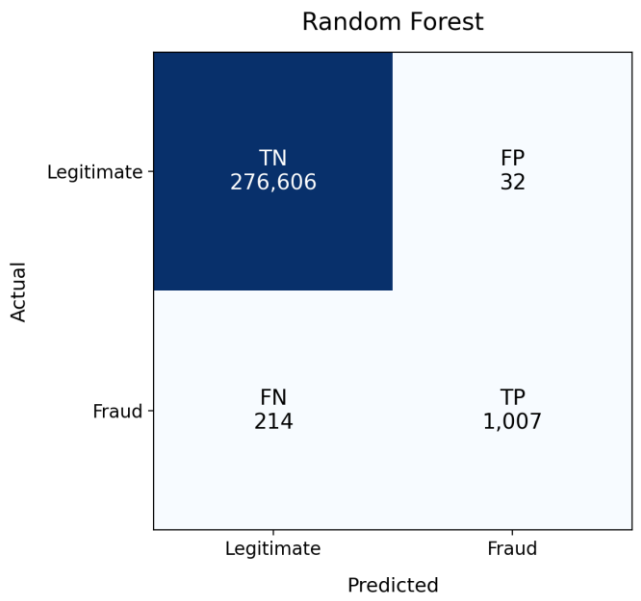
Metodika modelovania

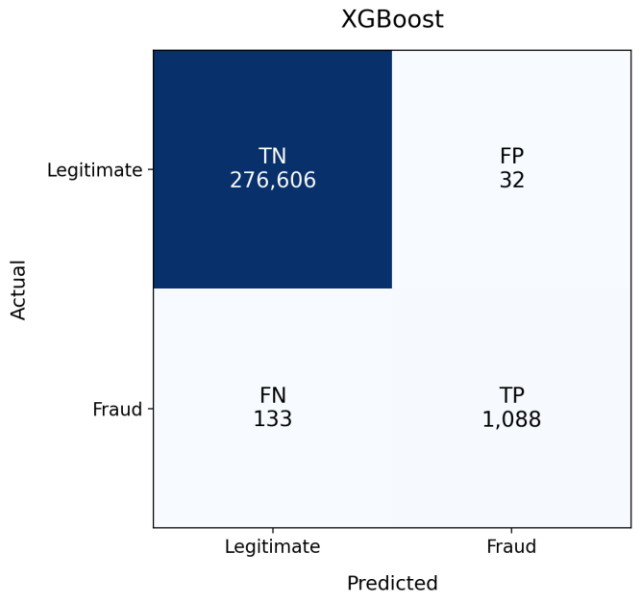
- Vstupné dáta
- Príprava dát a feature engineering
- Chronologické rozdelenie dát na train (70%), validation (15%) a test (15%) split
- Výber príznakov (Mutual information)
- Implementácia modelov: Logistická regresia, Random Forest, XGBoost
- Optimalizácia hyperparametrov (Optuna)
- Optimalizácia rozhodovacieho prahu
- Vyhodnotenie modelu
- SHAP analýza – globálna a fraudov

Porovnanie základných modelov

Model	Počet príznakov	PR-AUC	Precision	Recall	F1 score
Logistická regresia	20	0.38	0.81	0.27	0.4
Random Forest	20	0.93	0.97	0.82	0.89
XGBoost	20	0.97	0.97	0.89	0.92







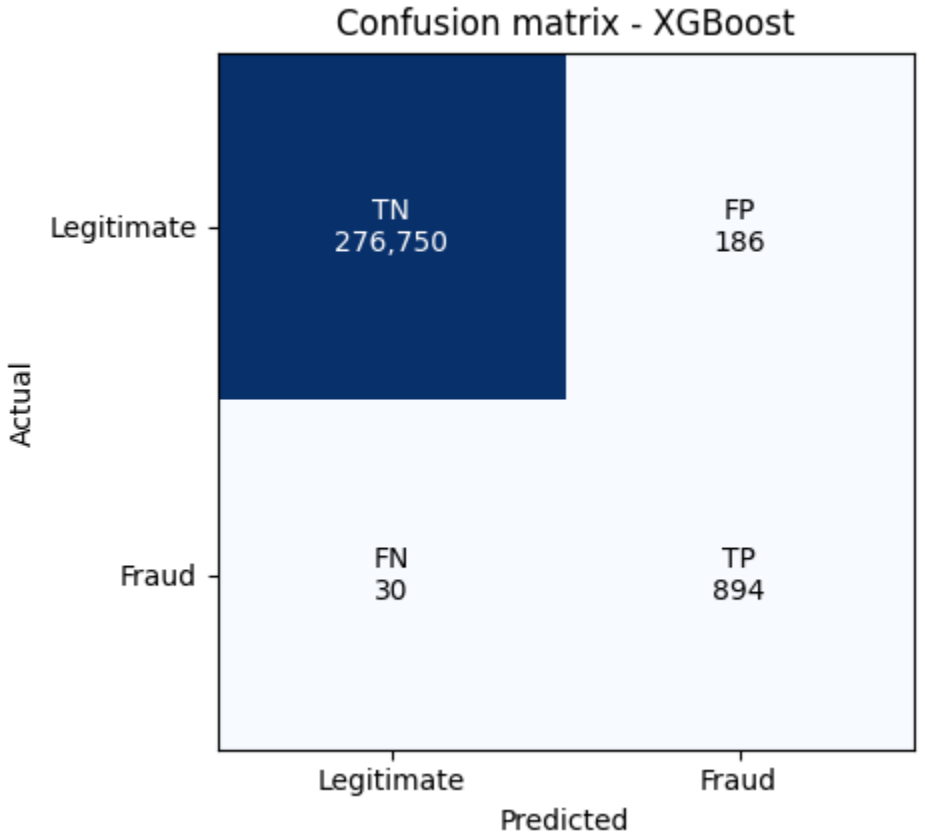
Optimalizácia hyperparametrov rozhodovacieho prahu

- **Cieľ optimalizácie:**
  - Zachytiť čo najviac podvodných transakcií pri zachovaní požadovanej úrovne Precision a zvládnuteľného počtu falošných alertov

Model	Hyperparametre	Threshold	AP	Presicion	Recall	F1	FP	FN
XGBoost - základný	predvolené	0.5	0.97	0.98	0.88	0.93	19	111
XGBoost - optimalizovaný	Optuna	0.5	0.98	0.97	0.91	0.93	30	87
XGBoost - finálny	Optuna	0.04	0.98	0.83	0.97	0.89	186	30

Výsledný model a jeho dopad

- Recall: **96.75%**
- Precision: **82.78%**
- PR-AUC: **0.9786**
- Zachytených podvodov: **894**
- Falošných alertov: **186**
- Nezachytených podvodov: **30**
- **Najvýznamnejšie príznaky podľa SHAP:**
  - Výška transakcie
  - Celkový objem transakcií za posledných 24 hodín
  - Kategória obchodníka
  - Rozdiel oproti priemernej sume transakcií klienta
  - Celkový objem transakcií za poslednú hodinu
  - Historická mediánová suma transakcií klienta
  - Hodina



Návrh produkčného riešenia

- **Real-time spracovanie**:
  - Prijatie transakcie a získanie dostupných údajov
  - Načítanie predpočítaných príznakov (história, typická výška transakcií, čas od poslednej platby)
  - Výpočet jednoduchých príznakov priamo z transakcie
  - Vyhodnotenie transakcie pomocou modelu (načítaného v pamäti)
  - Kombinácia ML skóre a deterministických pravidiel
  - Rozhodnutie: schválenie, dodatočné overenie alebo zamietnutie transakcie
- **Batch spracovanie:**
  - Priebežná aktualizácia historických príznakov po transakciách
  - Výpočet komplexnejších historických štatistík
  - Predpočítanie príznakov pre následné real-time vyhodnocovanie
- **Spätná väzba:**
  - Manuálne vyšetrovanie podozrivých transakcií
  - Dopĺňanie tréningových dát, pravidelný retraining a aktualizácia modelu
  - Monitoring výkonnosti modelu, kvality alertov a zmien v správaní podvodov

Obmedzenia a možné vylepšenia

- **Obmedzenia:**
  - Chýbajúci časový údaj o reálnom potvrdení podvodu
  - Chýbajúce meranie výpočtovej latencie pri real-time nasadení
  - Potreba validácie na produkčných dátach s ohľadom na reálne správanie klientov

- **Možné vylepšenia:**
  - Kombinácia s pravidlovým prístupom (deterministické pravidlá)
  - Real-time alebo pravidelný batch scoring
  - Využitie grafovej analýzy na odhaľovanie prepojení medzi podozrivými účtami
  - Priebežné sledovanie výkonnosti modelu a zmeny správania fraudu, využitie spätnej väzby od vyšetrovateľa

Ďakujem